Predicción del porcentaje de ONTs con firmware fuera de estándar por puerto PON

Juan Ignacio Forzani, Alejo Racca, Agustín Cesano
Ingeniería en Computación, Universidad Nacional de Rafaela (UNRaf), Rafaela, Santa Fe, Argentina

***Resumen*—Se estima, para cada uno de los 301 puertos PON de una red GPON de nueve localidades, la proporción de terminales ópticos (ONT) cuyo firmware difiere de la versión más frecuente de su modelo. Se comparan una regresión lineal (línea base), Ridge, Random Forest y Gradient Boosting contra un predictor constante, con una partición 80/20 y validación cruzada de cinco particiones. Ridge obtuvo el menor RMSE de validación cruzada (0,142) y, en prueba, R^2 = 0,59, R^2 ajustado = 0,38 y MAE = 0,088, frente a 0,128 del predictor constante, con lo que cumple los tres criterios fijados. Los ensambles de árboles sobreajustan, el error es mayor en los puertos con pocos equipos y agregar variables físicas de la OLT no mejora la predicción: el firmware fuera de estándar responde a factores administrativos y de composición del parque, no al estado de la red.**

***Palabras clave*—GPON, ONT, firmware, regresión, Ridge, validación cruzada, sesgo y varianza.**

I. Introducción

Las redes de acceso GPON conectan a cada cliente mediante un terminal óptico (ONT) que depende de un puerto PON de la terminal de línea (OLT) [1]. El firmware de las ONT condiciona su seguridad y sus funciones; en el inventario analizado, el 28,9 % de los 5114 equipos no tiene la versión más frecuente de su modelo. Actualizar equipo por equipo es costoso, mientras que actualizar un puerto completo en una ventana de mantenimiento aprovecha mejor cada intervención.

En el TP1 se observó que el modelo de ONT instalado depende fuertemente de la localidad. De ese hallazgo surge la pregunta de este trabajo: estimar, a partir de la composición de cada puerto, qué proporción de sus equipos está fuera del estándar, para priorizar los puertos donde una ventana de mantenimiento rinde más. Se comparan cuatro algoritmos de regresión bajo un marco experimental controlado y se analiza su ajuste en términos de sesgo y varianza [8].

II. Marco Experimental

A. Datos y variable objetivo

El inventario contiene 5114 ONT agregadas en 301 puertos PON. La variable objetivo es la proporción de equipos del puerto cuya versión de firmware difiere de la versión modal de su modelo. Esta definición de estándar es una regla de negocio fija, calculada sobre todo el inventario. La variable tiene media 0,29 y desvío 0,20; 26 puertos valen 0 y 5 valen 1.

B. Variables predictoras

Se usan la localidad y la tarjeta (codificación *one-hot*), la cantidad de equipos del puerto, los porcentajes de equipos con salida de TV y de equipos modernos, la cantidad de modelos distintos y la proporción de los cinco modelos más frecuentes en el conjunto de entrenamiento (EG8141A5, EG8143A5, CN1001, CN2002, RDC143). Se excluyen todas las variables derivadas de la versión de firmware (proporción de versiones V3 y cantidad de versiones), porque contienen la respuesta, además de los identificadores y de los indicadores de huecos de ID, no validados con la empresa. Con las 22 proporciones de modelo, la regresión lineal tiene 38 predictores para 240 puertos y su R^2 ajustado de prueba cae a −0,04, frente a 0,37 con cinco.

C. Partición y validación

Se reserva el 20 % de los puertos (61) como conjunto de prueba (semilla 42), que se usa una única vez al final. Con el 80 % restante (240 puertos) se aplica validación cruzada *k-fold* de cinco particiones, con mezcla y semilla 42, para elegir hiperparámetros y modelo. No hace falta agrupar porque cada fila ya es un puerto.

D. Métricas

Se informan MSE, RMSE, MAE, R^2 y R^2 ajustado en entrenamiento, validación cruzada (media ± desvío) y prueba. El R^2 ajustado se calcula como

$$R^2_{aj} = 1 - (1 - R^2) \cdot (n - 1) / (n - p - 1) \quad (1)$$

donde $p = 21$ es la cantidad de predictores efectivos (columnas *one-hot* menos una por variable categórica). No se usa MAPE porque 26 puertos tienen valor real nulo y la métrica divide por él.

III. Métodos

Todo el preprocesamiento (codificación *one-hot* que ignora categorías nuevas, imputación por mediana y estandarización) se encapsula en un *Pipeline* de scikit-learn [2], de modo que nada se ajusta con datos de validación o de prueba. La línea base es una regresión lineal por mínimos cuadrados; se la compara con Ridge [3], Random Forest [4] y Gradient Boosting [5], y con un predictor que devuelve siempre la media de entrenamiento. Los hiperparámetros se buscaron con *GridSearchCV* minimizando el RMSE de validación cruzada. En Ridge se probó α en {0,1; 1; 10} y se eligió α = 1. En Random Forest (300 árboles), *min_samples_leaf* en {1, 3, 5} y *max_depth* en {sin límite, 8}; se eligieron max_depth = 8, min_samples_leaf = 3, que mejoran el RMSE de validación 4,0 % respecto de los valores por defecto. En Gradient Boosting (200 árboles), *learning_rate* en {0,05; 0,1} y *max_depth* en {2, 3}; se eligieron learning_rate = 0,05, max_depth = 2 (mejora de 11,1 %).

El modelo final se eligió por el menor RMSE medio de validación cruzada, sin mirar la prueba. Sobre él se calcularon la importancia por permutación, el análisis de residuos con las pruebas de Shapiro-Wilk [6] y de Breusch-Pagan en la versión de Koenker [7], y la curva de aprendizaje. Como prueba adicional, el mejor modelo se repitió con tres variables por puerto del listado de la OLT del 29/10/2026: porcentaje de equipos en línea, distancia mediana y potencia recibida mediana.

IV. Resultados

TABLA I
Métricas de Regresión por Modelo

Modelo	R^2 entr.	R^2 VC (media ± desvío)	R^2 prueba	R^2 aj. prueba	RMSE prueba	MAE prueba
Constante (media)	0,00	−0,01 ± 0,01	−0,01	−0,01	0,184	0,128
Regresión lineal	0,58	0,49 ± 0,11	0,59	0,37	0,118	0,089
Ridge	0,57	0,49 ± 0,10	0,59	0,38	0,117	0,088
Random Forest	0,76	0,46 ± 0,12	0,62	0,41	0,113	0,085
Gradient Boosting	0,73	0,39 ± 0,22	0,60	0,39	0,116	0,083

VC: validación cruzada de cinco particiones sobre 240 puertos; prueba: 61 puertos. Errores en proporción (0,10 = 10 puntos porcentuales). Sombreado: modelo elegido.

La Tabla I resume las métricas. Todos los modelos superan con amplitud al predictor constante, cuyo R^2 de prueba es −0,01. Ridge y la regresión lineal son prácticamente equivalentes: su diferencia de RMSE en validación cruzada (0,1423 contra 0,1430) es muy inferior al desvío entre particiones (± 0,017). Ridge cumple los tres criterios SMART: $R^2 = 0,59 \geq 0,45$, R^2 ajustado $= 0,38 \geq 0,30$ y MAE $= 0,088 < 0,128$.

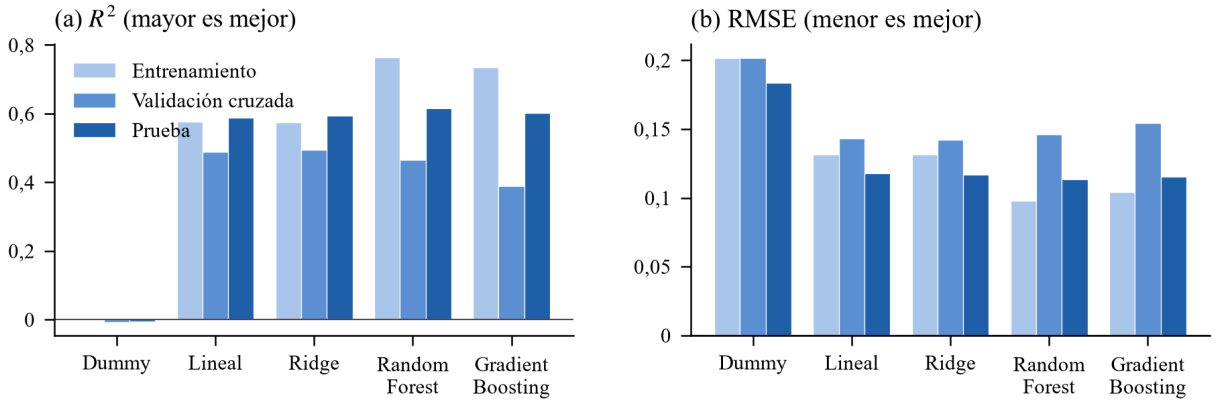


Fig. 1. R^2 (a) y RMSE (b) de cada modelo en entrenamiento, validación cruzada y prueba. Los ensambles muestran la mayor brecha entre entrenamiento y validación cruzada.

La Fig. 1 muestra el sobreajuste de los ensambles: Random Forest pasa de $R^2 = 0{,}76$ en entrenamiento a 0,46 en validación cruzada, y Gradient Boosting de 0,73 a 0,39. Todos los modelos logran mejor R^2 en prueba que en validación cruzada, lo que indica que la partición de prueba (61 puertos) resultó más sencilla que el promedio; por eso la selección se basa en la validación cruzada.

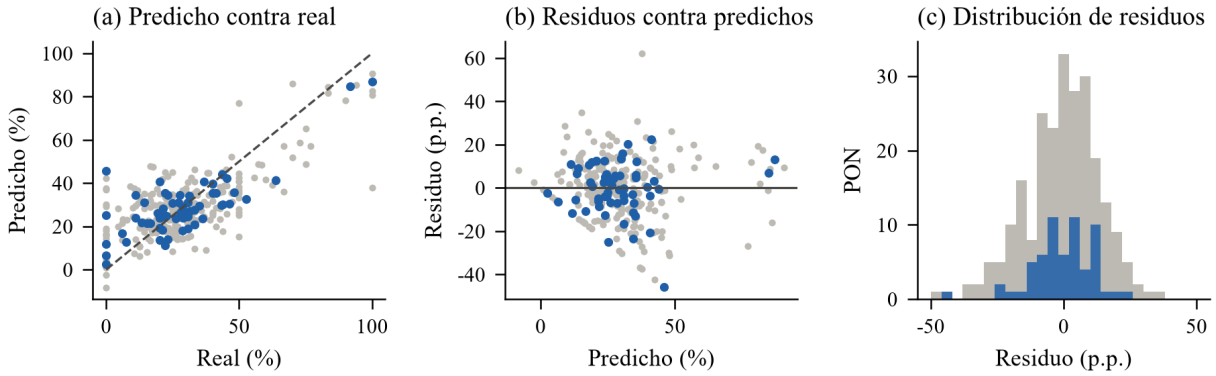


Fig. 2. Diagnóstico de Ridge: (a) valores predichos contra reales, con la diagonal de predicción perfecta; (b) residuos contra predichos; (c) distribución de los residuos. Gris: predicciones fuera de muestra en entrenamiento; azul: prueba.

Los residuos (Fig. 2) están centrados en cero (media −0,13 puntos porcentuales) pero no son normales (Shapiro-Wilk, $p = 0{,}0032$) y muestran heterocedasticidad leve (Breusch-Pagan, $p = 0{,}017$). El error absoluto decrece con el tamaño del puerto (Spearman, $\rho = -0{,}35$): en los 35 puertos con cinco equipos o menos el MAE es 0,157, frente a 0,101 en el resto.

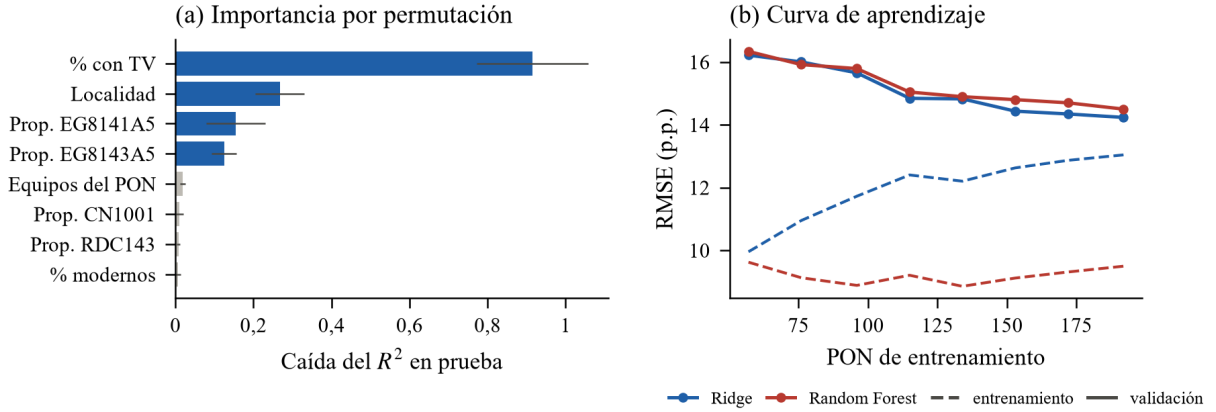


Fig. 3. (a) Importancia por permutación de Ridge en prueba (caída del R^2 al permutar cada variable). (b) Curvas de aprendizaje de Ridge y de Random Forest (RMSE de entrenamiento en trazo discontinuo y de validación en trazo continuo).

La variable más influyente es el porcentaje de equipos con TV (caída del R^2 de 0,91), casi idéntica a la proporción de EG8143A5 (correlación 0,99); permutadas juntas, el R^2 cae 1,34. Le sigue la localidad (0,27). En la Fig. 3b, la curva de Ridge converge con una brecha final de 1,2 puntos porcentuales, mientras que Random Forest mantiene 5,0. Por último, al incorporar las variables de la OLT el R^2 de validación cruzada baja de 0,49 a 0,46 y el R^2 ajustado de prueba, de 0,38 a 0,18.

V. Discusión

A. ¿Cuál es el modelo más adecuado y depende de la métrica?

Ridge es el más adecuado: tiene el menor RMSE y el mayor R^2 en validación cruzada, y la regresión lineal queda a una distancia despreciable. En prueba, Random Forest obtiene el mejor R^2 y RMSE y Gradient Boosting el mejor MAE, pero esa ventaja no se sostiene en validación cruzada; elegir por la prueba equivaldría a ajustar el modelo mirando el conjunto de evaluación. El MAE favorece a los árboles, que aciertan los puertos típicos, mientras que el RMSE penaliza los errores grandes en los puertos extremos, donde los modelos lineales son más estables. Como para la empresa importa no errar por mucho en un puerto, el RMSE es la métrica de selección más adecuada.

B. ¿Hubo sobreajuste o subajuste?

Random Forest y Gradient Boosting sobreajustan (brechas de R^2 entre entrenamiento y validación cruzada de 0,30 y 0,35): con 240 puertos, los árboles aprenden particularidades que no se repiten, lo que corresponde a varianza alta. Los modelos lineales no sobreajustan (brecha de 0,08), pero tienen sesgo moderado: su R^2 de entrenamiento (0,57) es el techo de un modelo aditivo con estas variables, y su curva de aprendizaje casi converge, por lo que más datos aportarían poco. La búsqueda de hiperparámetros ya redujo la varianza de los árboles, y limitar las proporciones de modelo a cinco fue la principal medida contra ella; para reducir el sesgo harían falta variables nuevas, como la fecha de la última campaña de actualización.

C. ¿Qué factores del dominio explican el desempeño?

Con 301 puertos y 21 predictores, los modelos flexibles no tienen datos suficientes para que sus interacciones compensen, y la relación es casi aditiva: composición del parque más localidad. Parte de lo que se predice es la propia definición del estándar: en el EG8143A5 la versión modal es la V3 y la mayoría de los equipos tiene la V5, más nueva. En total, 578 de los 1476 equipos fuera de estándar tienen una generación más nueva que la modal, lo que debe validarse con la empresa. Que las variables físicas de la OLT no aporten confirma que estar fuera de estándar es una cuestión administrativa. Los residuos sí conservan un patrón: los puertos chicos tienen proporciones muy variables (con dos equipos, solo 0, 0,5 o 1), lo que sugiere ponderar cada puerto por su cantidad de equipos o modelar la proporción con una regresión binomial.

VI. Conclusiones

Ridge estima el porcentaje de firmware fuera de estándar de cada puerto con un error medio de 8,8 puntos porcentuales en prueba y explica alrededor de la mitad de la variabilidad entre puertos (R^2 de 0,49 en validación cruzada y 0,59 en prueba), cumpliendo los criterios fijados. Con el volumen disponible, los ensambles de árboles no se justifican. Antes de usar el modelo para planificar actualizaciones, la empresa debe confirmar cuál es la versión de firmware correcta para cada modelo.

Referencias

[1] ITU-T, *Gigabit-capable passive optical networks (GPON): Physical media dependent (PMD) layer specification*, Rec. ITU-T G.984.2, Ginebra, Suiza, 2003 (Enmienda 1, 2006).

[2] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[3] A. E. Hoerl y R. W. Kennard, “Ridge regression: Biased estimation for nonorthogonal problems,” *Technometrics*, vol. 12, n.º 1, pp. 55–67, 1970.

[4] L. Breiman, “Random forests,” *Mach. Learn.*, vol. 45, n.º 1, pp. 5–32, 2001.

[5] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *Ann. Statist.*, vol. 29, n.º 5, pp. 1189–1232, 2001.

[6] S. S. Shapiro y M. B. Wilk, “An analysis of variance test for normality (complete samples),” *Biometrika*, vol. 52, n.º 3/4, pp. 591–611, 1965.

[7] R. Koenker, “A note on studentizing a test for heteroscedasticity,” *J. Econometrics*, vol. 17, n.º 1, pp. 107–112, 1981.

[8] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2.ª ed. Nueva York, NY, EE. UU.: Springer, 2009.