¿Tiene el cliente la señal de la fibra en riesgo? Clasificación de ONTs en una red GPON

Juan Ignacio Forzani, Alejo Racca, Agustín Cesano
Ingeniería en Computación, Universidad Nacional de Rafaela (UNRaf), Rafaela, Santa Fe, Argentina

***Resumen*—Se clasifica si la potencia óptica que recibe cada ONT en línea está en riesgo (por debajo de −25 dBm) usando solo información disponible antes de medirla: ubicación, equipo y la señal media de los vecinos del mismo puerto. Sobre 4872 ONT (11,2 % en riesgo), con una partición estratificada y agrupada por puerto, se comparan regresión logística, árbol de decisión, KNN y Naive Bayes, más dos ensambles y K-Means. La regresión logística obtuvo la mejor PR-AUC en validación cruzada y, en prueba, ROC-AUC = 0,70 y PR-AUC = 0,39 (tasa base 0,11), con lo que cumple los criterios fijados. Una regla sin aprendizaje basada solo en la señal de los vecinos alcanza un desempeño equivalente (ROC-AUC = 0,71): el riesgo depende de la fibra compartida del puerto y no del equipo. Los ensambles sobreajustan sin mejorar la prueba, y el clustering revela un grupo de tendidos largos con 26,7 % de clientes en riesgo.**

***Palabras clave*—GPON, potencia óptica, clasificación desbalanceada, regresión logística, validación agrupada, K-Means.**

I. Introducción

En una red GPON, la potencia óptica que recibe cada ONT debe superar la sensibilidad mínima del receptor, que para la clase B+ es de −27 dBm [1]. Un cliente con señal cercana a ese límite tiene servicio, pero cualquier degradación adicional lo deja sin conexión. Este trabajo define como *en riesgo* a los equipos que reciben menos de −25 dBm (2 dB de margen) y busca anticiparlos sin medir su propia señal, lo que permite elegir el puerto de cada alta nueva, adelantarse a los reclamos y distinguir si el problema está en la fibra o en el módem.

La pregunta surge de una fuga de información detectada en el TP1: un modelo que usa la señal del propio equipo para predecir su estado acierta sin aprender nada. Los datos son el inventario del TP1 cruzado con el listado de la OLT que entregó la empresa el 29/10/2026, uso confirmado por la cátedra.

II. Marco Experimental

A. Problema y distribución de clases

Es una clasificación binaria sobre los 4872 equipos en línea que cruzan con el inventario y tienen lectura válida. La clase *en riesgo* tiene 548 equipos (11,2 %), un desbalance de uno a ocho: un clasificador que siempre predice *sin riesgo* logra exactitud 0,89 sin detectar a nadie. Por eso se priorizan métricas sensibles a la clase minoritaria.

B. Variables

Entran la localidad, el modelo de ONT, los puertos LAN y la tecnología Wi-Fi (*one-hot*); y el slot, el puerto, el ID, la posición relativa en el puerto, los equipos del puerto, la generación de firmware, el indicador de firmware fuera de estándar, la distancia a la OLT y la señal media de los *otros* equipos en línea del mismo puerto:

$$v_i = (1 / (n_{\mathrm{PON}} - 1)) \cdot \Sigma_{j \neq i} \mathrm{RXP}_j \qquad (1)$$

donde la suma recorre los equipos en línea del mismo puerto que el equipo i y n_{PON} es su cantidad. Se excluyen la potencia recibida y transmitida, el estado y el nivel de señal del propio equipo, porque son la respuesta. La señal de los vecinos sí es legítima: cuando se instala un cliente, la de sus vecinos ya está medida y la suya todavía no existe.

C. Partición y validación

Los equipos de un puerto comparten la fibra, de modo que repartirlos entre entrenamiento y prueba filtraría información. Se usa *StratifiedGroupKFold* de cinco particiones (mezcla, semilla 42) con el puerto como grupo; la prueba es una de esas particiones (973 equipos de 63 puertos, 11,1 % en riesgo) y no comparte ningún puerto con el entrenamiento (3899 equipos, 11,3 % en riesgo). La validación cruzada aplica la misma estrategia sobre el entrenamiento.

D. Métricas

Se informan exactitud y exactitud balanceada; precisión, *recall* y F1 de la clase en riesgo y ponderados; Kappa de Cohen [10]; ROC-AUC y PR-AUC, más informativa con clases desbalanceadas [11]. Todas se calculan en entrenamiento, validación cruzada y prueba. La referencia es un clasificador que predice la proporción de clases, al que se suma una regla sin aprendizaje que ordena a los clientes por la señal de sus vecinos.

III. Métodos

El preprocesamiento (*one-hot*, imputación por mediana y estandarización) va dentro de un *Pipeline* [2]. La línea base es la regresión logística [3] (C en {0,01; 0,1; 1; 10}; se eligió C = 0,01). Se la compara con un árbol de decisión [4] (max_depth = 8, min_samples_leaf = 50), KNN [5] (n_neighbors = 101, weights = distance) y Naive Bayes gaussiano [6] (var_smoothing = 0,1). Contra el desbalance [9] se usa *class_weight* balanceado en la regresión logística, el árbol y Random Forest. En KNN, Naive Bayes y Gradient Boosting el umbral de decisión se elige en validación cruzada (F1 máximo sobre probabilidades fuera de muestra) y, para medirlos en validación cruzada, se vuelve a elegir dentro de cada partición.

Los hiperparámetros se buscaron con *GridSearchCV* y la misma validación agrupada, maximizando la PR-AUC. El clasificador se eligió entre los cuatro individuales por la PR-AUC media de validación cruzada. Se agregan la importancia por permutación, el análisis del umbral de decisión y la curva de aprendizaje.

IV. Resultados

TABLA I
Métricas De Clasificación En Prueba (clase En Riesgo)

Modelo	Exact.	Exact. bal.	Precisión	Recall	F1	κ	ROC-AUC	PR-AUC
Reg. logística	0,77	0,68	0,25	0,56	0,35	0,23	0,70	0,39
Árbol de decisión	0,75	0,65	0,23	0,52	0,32	0,19	0,71	0,40
KNN	0,85	0,63	0,34	0,33	0,33	0,25	0,66	0,26
Naive Bayes	0,80	0,61	0,24	0,36	0,29	0,18	0,67	0,28
Random Forest	0,85	0,65	0,35	0,40	0,37	0,29	0,68	0,31
Gradient Boosting	0,88	0,66	0,46	0,37	0,41	0,35	0,71	0,43
Constante (prior)	0,89	0,50	0,00	0,00	0,00	0,00	0,50	0,11
Regla de vecinos	—	—	—	—	—	—	0,71	0,40

Prueba: 973 equipos. Umbral 0,5, salvo KNN, Naive Bayes y Gradient Boosting, cuyo umbral se eligió en validación cruzada. La regla de vecinos no es un clasificador: solo ordena por $-v_i$.

La Tabla I resume el desempeño en prueba. La regresión logística detecta 60 de los 108 clientes en riesgo (*recall* 0,56) a costa de 177 falsas alarmas (precisión 0,25) y cumple los criterios SMART: ROC-AUC = 0,70 ≥ 0,68 y PR-AUC = 0,39 ≥ 0,22. La regla de los vecinos obtiene ROC-AUC = 0,71 y PR-AUC = 0,40, a la par del mejor clasificador.

TABLA II
Ajuste De Cada Modelo En Entrenamiento, Validación Cruzada Y Prueba

Modelo	ROC-AUC entr.	ROC-AUC VC	ROC-AUC prueba	PR-AUC VC	Diagnóstico
Reg. logística	0,74	0,72 ± 0,04	0,70	0,32 ± 0,11	ajuste razonable
Árbol de decisión	0,84	0,67 ± 0,08	0,71	0,30 ± 0,13	sobreajuste
KNN	1,00	0,69 ± 0,04	0,66	0,30 ± 0,09	sobreajuste
Naive Bayes	0,73	0,71 ± 0,06	0,67	0,28 ± 0,08	ajuste razonable
Random Forest	0,92	0,71 ± 0,06	0,68	0,34 ± 0,15	sobreajuste
Gradient Boosting	0,80	0,66 ± 0,06	0,71	0,25 ± 0,04	sobreajuste

Diagnóstico: sobreajuste si la ROC-AUC de entrenamiento supera a la de validación cruzada o a la de prueba en más de 0,10; subajuste si la ROC-AUC de entrenamiento es menor que 0,68.

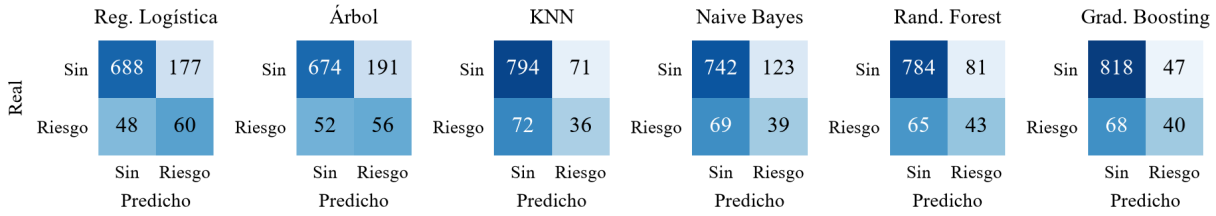


Fig. 1. Matrices de confusión en prueba (filas: clase real; columnas: clase predicha). El color indica la proporción de cada fila.

Las matrices de la Fig. 1 muestran el compromiso entre *recall* y precisión: los modelos que más clientes en riesgo detectan son los que más falsas alarmas generan. La importancia por permutación confirma que casi toda la información está en la señal de los vecinos (caída de PR-AUC de 0,265); el resto de las variables aporta cerca de cero. Si se baja el umbral hasta detectar el 80 % de los casos en validación cruzada, en prueba el *recall* sube a 0,74, pero se marcan 547 de 973 equipos y solo 15 % de las alarmas son reales.

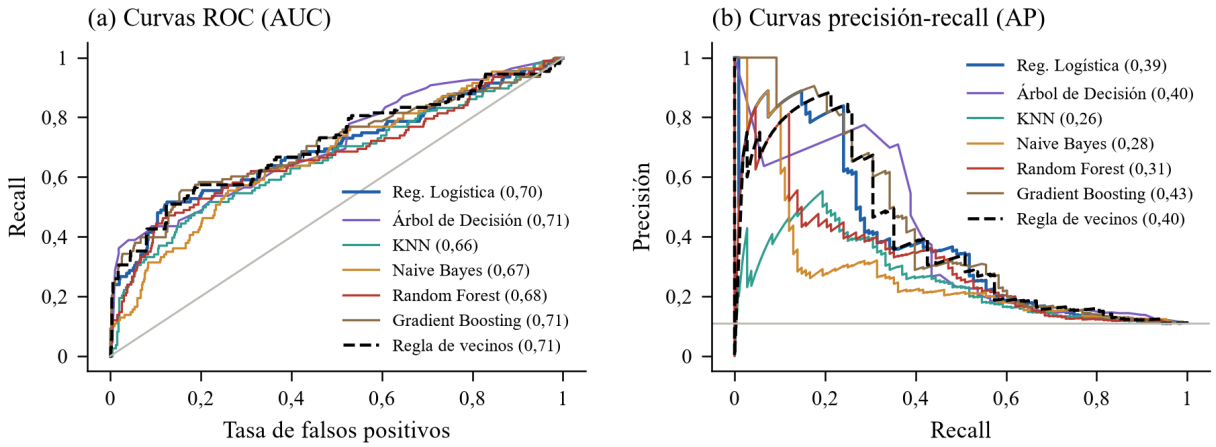


Fig. 2. Curvas ROC (a) y precisión-recall (b) en prueba. La regla de los vecinos (trazo discontinuo) queda entre los clasificadores; la línea gris indica el azar.

En la Fig. 2 todas las curvas quedan próximas entre sí y lejos de la esquina ideal: ningún modelo separa las clases mucho mejor que otro.

V. Actividades Complementarias

A. Ensamble

Random Forest [7] (*bagging*, 300 árboles; max_depth = 10, min_samples_leaf = 5) y Gradient Boosting [8] (*boosting*, 200 árboles; learning_rate = 0,05, max_depth = 2) se compararon con las mismas métricas (Tablas I y II). Random Forest tiene la mayor PR-AUC de validación cruzada (0,34 contra 0,32), pero la diferencia es muy inferior a su desvío (± 0,15); además sobreajusta (ROC-AUC de entrenamiento 0,92) y en prueba no alcanza la meta (ROC-AUC = 0,675). Gradient Boosting es el peor en validación cruzada (0,25) y el mejor en prueba (0,43), señal de inestabilidad. Su búsqueda de hiperparámetros tardó 28 s y 26 s, contra 3,3 s de la regresión logística, y se pierde interpretabilidad: la ganancia no justifica la complejidad.

B. Clustering

Se aplicó K-Means [12] con k de 2 a 8, elegido por el coeficiente de silueta [13] junto con el codo y el índice de Davies-Bouldin [14]. El mejor valor es $k = 2$, con silueta 0,24 (estructura débil), y los grupos casi no coinciden con la clase: índice de Rand ajustado [15] de 0,16 (Fig. 3a-b). Con $k = 4$ aparece, sin embargo, una subestructura (Fig. 3c): un grupo de 675 equipos con 26,7 % en riesgo, frente a 7,6 % a 11,2 % en los demás, formado por tendidos largos (distancia mediana 8,2 km) con señal de vecinos débil (−23,3 dBm de media) y concentrado en Bernardo de Irigoyen. El clustering aporta así un criterio para priorizar el mantenimiento que la clasificación supervisada no muestra.

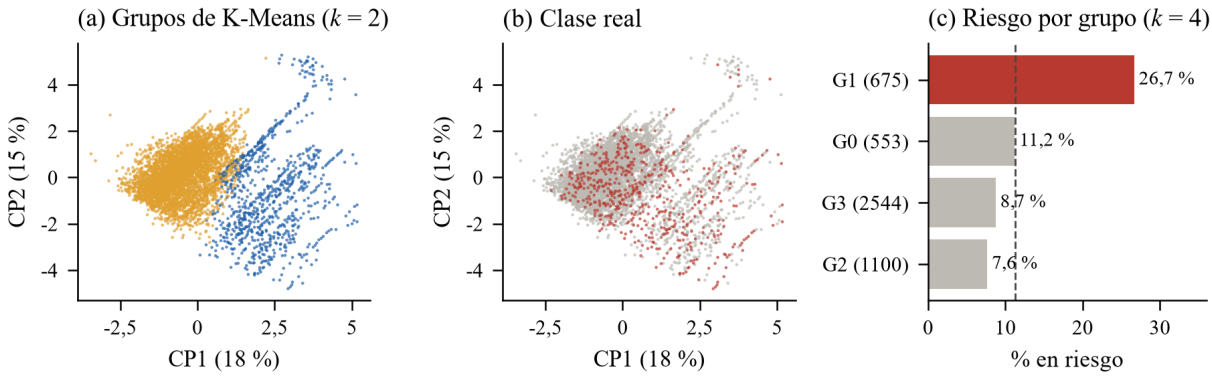


Fig. 3. K-Means con las mismas variables, sin la etiqueta: (a) proyección PCA coloreada por grupo (k = 2); (b) la misma proyección coloreada por clase real (rojo: en riesgo; gris: sin riesgo); (c) proporción de equipos en riesgo en cada grupo con k = 4 (la línea discontinua es la tasa global).

VI. Discusión

A. ¿Cuál es el clasificador más adecuado y cambia al priorizar recall o precisión?

La regresión logística es la más adecuada: tiene la mejor PR-AUC media de validación cruzada entre los individuales, no sobreajusta y es la que más clientes en riesgo encuentra en prueba (*recall* 0,56). Si se priorizara la precisión, convendría Gradient Boosting (precisión 0,46), que da solo 47 falsas alarmas pero deja sin detectar a 68 de 108 clientes en riesgo. Como un cliente en riesgo no detectado termina en reclamo, se prioriza el *recall*; el umbral que maximiza F2 (0,51) coincide prácticamente con 0,5 porque el peso balanceado ya desplaza la decisión.

B. ¿Hubo sobreajuste o subajuste? ¿Qué impacto tuvo el desbalance?

Sobreajustan árbol de decisión, KNN, Random Forest y Gradient Boosting (Tabla II); el caso extremo es KNN, con ROC-AUC de entrenamiento 1,00 porque con ponderación por distancia cada equipo se reconoce a sí mismo. La regresión logística y Naive Bayes están equilibrados (brechas de 0,02 y 0,02) pero tienen sesgo alto: su curva de aprendizaje queda plana (PR-AUC de validación 0,30 con 467 equipos y 0,32 con 3116), de modo que el límite es la información, no la cantidad de datos. El desbalance vuelve engañosa la exactitud y, sin corrección, anula la detección: con el umbral 0,5 el *recall* en prueba sería 0,00 en KNN, 0,24 en Naive Bayes y 0,24 en Gradient Boosting, frente a 0,33, 0,36 y 0,37 con el umbral elegido.

C. ¿Qué factores del dominio explican el desempeño?

La potencia recibida depende del divisor óptico, los empalmes y los conectores que el cliente comparte con su puerto, por lo que la señal de los vecinos concentra la información y el modelo de ONT o el firmware casi no influyen. Aunque hay 4872 equipos, la información relevante vive en 300 puertos; al separar por puerto, los modelos flexibles aprenden ruido de cada uno. Las clases se separan poco (ninguna ROC-AUC de validación cruzada supera 0,72). El clustering no reproduce las clases, pero identifica los tendidos largos como subgrupo de mayor riesgo, y el ensamble no justifica su complejidad.

VII. Conclusiones

Sin medir la señal de un cliente, la regresión logística identifica a los clientes en riesgo mucho mejor que el azar (PR-AUC 0,39 contra 0,11) y cumple los criterios fijados. Casi todo ese poder proviene de la señal de los vecinos del puerto, al punto de que una regla sin aprendizaje rinde igual: el riesgo está en la fibra compartida y no en el módem. Para elegir dónde conectar a un cliente nuevo alcanza con observar la señal de sus futuros vecinos, y los tendidos largos detectados por el clustering son el punto de partida para el mantenimiento preventivo.

Referencias

[1] ITU-T, *Gigabit-capable passive optical networks (GPON): Physical media dependent (PMD) layer specification*, Rec. ITU-T G.984.2, Ginebra, Suiza, 2003 (Enmienda 1, 2006).

[2] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[3] D. R. Cox, “The regression analysis of binary sequences,” *J. Roy. Statist. Soc. B*, vol. 20, n.º 2, pp. 215–242, 1958.

[4] L. Breiman, J. H. Friedman, R. A. Olshen y C. J. Stone, *Classification and Regression Trees*. Belmont, CA, EE. UU.: Wadsworth, 1984.

[5] T. Cover y P. Hart, "Nearest neighbor pattern classification," *IEEE Trans. Inf. Theory*, vol. 13, n.º 1, pp. 21–27, 1967.

[6] T. Hastie, R. Tibshirani y J. Friedman, *The Elements of Statistical Learning*, 2.ª ed. Nueva York, NY, EE. UU.: Springer, 2009.

[7] L. Breiman, "Random forests," *Mach. Learn.*, vol. 45, n.º 1, pp. 5–32, 2001.

[8] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *Ann. Statist.*, vol. 29, n.º 5, pp. 1189–1232, 2001.

[9] H. He y E. A. Garcia, "Learning from imbalanced data," *IEEE Trans. Knowl. Data Eng.*, vol. 21, n.º 9, pp. 1263–1284, 2009.

[10] J. Cohen, "A coefficient of agreement for nominal scales," *Educ. Psychol. Meas.*, vol. 20, n.º 1, pp. 37–46, 1960.

[11] T. Saito y M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLoS ONE*, vol. 10, n.º 3, e0118432, 2015.

[12] S. Lloyd, "Least squares quantization in PCM," *IEEE Trans. Inf. Theory*, vol. 28, n.º 2, pp. 129–137, 1982.

[13] P. J. Rousseeuw, "Silhouettes: A graphical aid to the interpretation and validation of cluster analysis," *J. Comput. Appl. Math.*, vol. 20, pp. 53–65, 1987.

[14] D. L. Davies y D. W. Bouldin, "A cluster separation measure," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. PAMI-1, n.º 2, pp. 224–227, 1979.

[15] L. Hubert y P. Arabie, "Comparing partitions," *J. Classif.*, vol. 2, n.º 1, pp. 193–218, 1985.